

결과 보고서

문제명	국내외 연구데이터에 대한 연관 논문·데이터 추천 에이전트 개발
팀명	하이라이트
제안 제목	sLLM 기반 논문·데이터셋 추천 에이전트 개발

1. 개요

1.1 문제 정의

국내외 연구데이터 포털인 DataON에는 방대한 양의 데이터셋이 등록되어 있으나, 연구자들이 특정 데이터셋과 의미적으로 깊이 연관된 다른 데이터셋이나 이를 활용한 연구 논문을 효율적으로 탐색하는 데에는 어려움이 있다. 키워드 기반의 단순 검색은 데이터의 맥락적, 의미적 연관성을 파악하는 데 한계가 있으며, 이는 데이터의 활용도 및 이해도를 저해하는 요인으로 작용한다.

1.2 개발 목표 및 결과

본 프로젝트는 소규모 언어모델(sLLM) 기반 의미 추론 기능을 활용하여, 고도화된 논문·데이터셋 추천 에이전트를 개발하였다.

- 사용자가 제시한 연구데이터(제목, 설명)의 의미를 깊이 이해
- DataON 및 ScienceON의 방대한 자료 중 의미적으로 관련성이 높은 연구논문과 데이터셋을 추천
- 추천에는 상세한 추천 사유, 정량화된 관련성 점수, 추천 수준(강추/추천/참고), 원문 URL 포함

1.3 핵심 기능

- 의미 기반 검색: 입력 데이터의 핵심 주제와 맥락 파악 후 관련 콘텐츠 추천
- 다차원적 추천 정보 제공: 제목, 설명, URL과 함께 추천 점수, 추천 사유, 추천 등급 제공
- 경량화 및 고효율화: 중저사양 H/W에서도 빠른 응답 시간을 보장

2. 활용 데이터

추천 에이전트는 KISTI 공개 API를 통해 데이터를 수집하고 활용하였다.

- DataON API: 국내외 연구데이터셋 정보(제목, 설명, 키워드, URL) 수집

- ScienceON API: 국내외 학술논문 정보(제목, 초록, 키워드, URL) 수집
- 데이터 수집 과정에서 HTML 태그 제거, 특수문자 정제 등 기본 전처리 과정을 수행하였다.

3. 모델 개발 방법

추천 에이전트는 광범위한 후보군을 빠르게 필터링하고, 소수의 유망한 후보를 깊이 있게 분석하는 다단계 파이프라인으로 구성된다. 이는 속도와 정확성을 모두 확보하기 위한 전략으로, LLM과 임베딩 모델을 유기적으로 결합하여 추천의 정확도를 높였다.

3.1 시스템 아키텍처

본 시스템은 사용자 입력부터 최종 추천까지 체계적인 정보 처리 과정을 따른다. 각 단계는 다음 단계의 입력이 되어 점진적으로 추천의 질을 높이는 구조로 설계되었다.



그림 1 시스템 아키텍처 흐름

3.2 1단계: LLM 기반 의미 분석 및 후보군 생성

① 입력 데이터 특징 추출:

- 사용자가 입력한 데이터셋의 제목과 설명을 Qwen-14B 모델에 전달
- 데이터의 '핵심 목표'와 '주요 방법론'을 JSON 형식으로 구조화하여 추출

이는 단순 키워드를 넘어 데이터의 근본적인 목적과 기술적 접근법을 이해하는 단계로, 추천 과정 전반에 걸쳐 컨텍스트를 유지하는 기준 정보가 된다.

② 2단계 연쇄 프롬프트(2-Step Chain) 기반 검색어 생성:

- 1단계 (키워드 브레인스토밍): '목표'와 '방법론'을 기반으로 상위 연구 분야를 확장 탐색하여 핵심 키워드 1차 생성
- 2단계 (키워드 구문 조합): 생성된 키워드를 LLM에 재입력해 전문 용어나 연구 분야 단위로 재조합, 검색 효율 극대화

③ API 검색 및 후보군 확보:

- 재조합된 검색어로 DataON·ScienceON API 호출
- 관련 논문·데이터셋 50~100건 후보군 확보

3.3 2단계: 하이브리드 재정렬 및 최종 추천 생성

- ① 1차 순위 선정 (임베딩 유사도 기반)
 - 모델: paraphrase-multilingual-MiniLM-L12-v2 사용
 - 입력·후보 텍스트를 벡터화 후 코사인 유사도 계산
 - 상위 10~15개 후보 선정 (대규모 후보군의 빠른 1차 필터링)
- ② sLLM 기반 재정렬 (Re-ranking):
 - 모델: Qwen-14B
 - 입력 데이터의 ‘핵심 목표’·‘주요 방법론’과 후보 내용을 비교
 - 문맥적 관련성을 1~10점으로 평가하여 재정렬 점수 부여
- ③ 최종 점수 계산 및 순위 확정:
 - 최종 점수 = 0.6 × 유사도 점수 + 0.4 × (재정렬 점수 × 10)
 - 상위 3~5개 후보를 최종 추천으로 선정
- ④ 추천 사유 생성
 - sLLM이 각 후보의 구체적 연관성을 2~3문장으로 설명
 - ‘강추’, ‘추천’, ‘참고’ 등 등급 부여 (설명가능 AI 기반 결과 제공)

입력 데이터셋	추천 대상	유사도	재정렬	최종 점수	추천 등급	추천 사유
의료 영상 데이터셋	Perspectives in Radiomics ...(생략)...	49.94	8.0	61.96	추천	의료 영상 데이터를 활용한 진단 및 치료 전략 개발이라는 주제를 공유 ...(생략)...
	Digital twin in healthcare ...(생략)...	60.38	6.0	60.23	추천	의료 분야에서 데이터 기반 기술의 활용이라는 공통 주제를 공유 ...(생략)...
	Digital Twin in Healthcare ...(생략)...	51.72	7.0	59.09	추천	의료 분야에서 데이터 기반의 진단 및 관리 전략에 초점 ...(생략)...

표 1. 추천 결과 예시

표 1은 제안된 하이브리드 재정렬 프로세스를 통해 산출된 최종 추천 결과의 예시를 나타낸다.

3.4 프롬프트 설계 및 LLM 응답 제어

본 연구에서는 sLLM(Qwen 2.5 14B-Instruct)의 의미 추론 능력을 최대한 활용하기 위해, ‘역할(Role) 명시형 + 구조적 출력 제약형(System-guided Prompt)’ 전략을 적용하였다. 이는 모델이 불필요한 문장을 생성하거나 주제를 벗어난 출력을 내는 문제를 방지하고, 재현 가능한 결과와 일관된 추천 품질을 확보하기 위한 핵심 요소이다.

① 프롬프트 구조 설계

프롬프트는 System Prompt, User Prompt, Few-shot 예시의 3단 구성으로 설계되었다.

▪ System Prompt (역할 부여):

모델에게 “연구데이터 추천 전문가”로서의 역할을 명시하고, 입력 데이터의 제목과 설명을 바탕으로 ‘핵심 목표(Goal)’, ‘주요 방법론(Methodology)’, ‘연구 주제(Field)’를 구조적으로 추출하도록 지시하였다.

[System Prompt 예시]

너는 연구데이터 추천 전문가야.

사용자가 입력한 데이터의 제목과 설명을 기반으로

① 연구의 핵심 목표, ② 주요 방법론, ③ 관련 연구 분야를 JSON 형태로 요약해.

불필요한 문장이나 주석은 출력하지 마.

▪ User Prompt (입력 데이터 기반 질의):

사용자가 입력한 DataON 데이터셋의 제목(title)과 설명(description)을 그대로 포함시켜 모델이 맥락적으로 풍부한 의미를 이해하도록 구성하였다.

[User Prompt 예시]

제목: {dataset_title}

설명: {dataset_description}

위 정보를 바탕으로 위에서 정의한 JSON 형식으로 출력해줘.

▪ Few-Shot 예시 (출력 형식 고정):

모델이 일관된 JSON 구조를 유지하도록 두세 개의 예시 출력을 함께 제공하였다. 이를 통해 필드 누락이나 항목 혼동을 최소화하고, 구조화된 결과 생성의 안정성을 높였다.

② 2단계 연쇄 프롬프트(Chain-of-Prompt) 설계

1단계에서 추출된 ‘핵심 목표’와 ‘방법론’을 입력으로 하여, 2단계에서는 검색 최적화용 확장 키워드(Expanded Research Keywords)를 생성하도록 설계하였다. 이로써 단순 키워드 나열이 아닌, 의미적으로 풍부한 검색 질의가 가능해졌다.

[Step 2 Prompt 예시]

다음 연구의 목표와 방법론을 기반으로,

연구데이터 포털 검색에 적합한 5~10개의 전문 연구 키워드를 생성해줘.

형식: ["키워드1", "키워드2", ...]

이 과정을 통해 생성된 키워드는 DataON 및 ScienceON API 검색 단계에 활용되어, 의미 기

반 추천의 탐색 범위와 정밀도를 동시에 향상시켰다.

③ 응답 제어 및 품질 개선

- Output Parser 검증 로직을 통해 JSON 구조가 불일치하거나 필드가 누락된 경우 자동 재시도를 수행하도록 설계하였다.
- Temperature=0.2, Max Token=512로 설정하여 응답 일관성을 확보하고 불필요한 서술을 방지하였다.

4. 실험 및 평가

4.1 성능 검증 H/W 환경

본 연구의 시스템은 Intel i5 CPU, 16GB RAM, NVIDIA GeForce RTX 3060으로 구성된 중저 사양 환경에서 실험되었다.

4.2 정량 평가

4.2.1 평가 데이터셋

평가용 데이터셋은 LLM(Google Gemini)이 Qwen 기반 추천 시스템의 결과를 평가하여 생성한 pseudo-ground-truth 기반의 데이터셋 qwen_llm_judge_result.json으로 구성하였다. 생성 절차는 다음과 같다.

① 1단계: qwen_recommend_results.json

Qwen 기반 추천 시스템이 DataON 원본 데이터셋 50건을 대상으로 생성한 결과이다. 각 항목은 3~5개의 논문·데이터셋 추천을 포함하며, 총 약 250개의 추천 관계를 정의한다.

② 2단계: qwen_llm_judge_results.json

LLM(Google Gemini)이 각 추천 사유의 논리성·일관성을 평가(0-3점)하여 점수를 부여한 결과이다. 이 점수를 pseudo-ground-truth로 활용하여, 비정답형 추천 문제 상황에서도 정량적 검증이 가능하도록 구성하였다.

4.2.2 평가 방법론

본 연구는 정답이 명시적으로 존재하지 않는 추천 문제의 평가를 위해, 최신 연구에서 제시된 LLM-as-a-Judge 프레임워크를 적용하였다.

- Pseudo-ground-truth 구축

사용자 피드백(클릭, 평점 등)에 기반한 정답 데이터셋이 존재하지 않는 환경에서, Gemini 모델을 정성 평가자로 설정하고, 각 추천 사유의 일관성·논리성을 평가해 0-3점의 pseudo-ground-truth를 자동 생성하였다.

- 정량 지표 산출

Gemini가 부여한 점수를 0-1 범위로 정규화하고, 추천 결과의 품질을 다음 다섯 가지 지표로 평가하였다.

지표	점수
nDCG@10	추천 순위와 관련성을 동시에 반영
MRR@10	첫 번째 관련 항목의 평균 순위
Recall@5	상위 5개 추천 내 실제 관련 항목 포함 비율
Precision@5	상위 5개 추천 중 정확히 맞힌 추천의 비율
F1@5	Precision과 Recall의 균형을 나타내는 평균 지표

표 2 자체 평가 결과

이 접근은 Chiang et al. (2023)¹⁾ 등에서 제안된 “정답 부재 상황에서의 자동 평가 기법”을 기반으로 하며, 데이터 부족 환경에서도 일관성과 재현성을 확보할 수 있는 평가 체계를 제공한다.

4.2.3 LLM 평가 프롬프트 설계

LLM의 평가 프롬프트는 0-3점 척도와 Chiang et al. (2023)¹⁾에서 제시된 단일 평가 구조 (Single-Answer Grading)를 채택하였다. 또한 AlpacaEval 2.0 및 GPT-Eval의 편향 완화 원칙을 참고하여 점수 분포의 균형과 일관성을 확보하였다.

▪ 입력 구성 요소

Gemini는 아래 입력을 바탕으로 논리성과 일관성을 평가하였다.

1. 평가 대상 데이터셋 제목 (query_title)
 2. 추천 항목 제목 (cand_title)
 3. 추천 사유 (cand_reason)

▪ 평가 기준

Gemini는 아래 기준을 가지고 점수를 제시하였다.

점수	기준 요약
0	무관, 비논리
1	약한 연관성
2	논리적 관련성
3	고도 연관, 정교한 논리

표 3 LLM 평가 프롬프트의 점수에 따른 기준 요약

0점: 두 항목 간 주제나 데이터의 연관성이 거의 없고, 추천 사유가 논리적으로 성립하지 않음. 핵심 개념을 잘못 연결하거나, 문장이 단순히 유사성을 주장할 뿐 구체적 근거가 없음.

1) Zheng, L., Chiang, W. L., Sheng, Y., Zhuang, S., Wu, Z., Zhuang, Y., ... & Stoica, I. (2023). Judging llm-as-a-judge with mt-bench and chatbot arena. Advances in neural information processing systems, 36, 46595-46623.

1점: 일부 관련성이 있으나, 근거가 매우 약하거나 일반적인 수준에 머무름. “둘 다 ~이다”, “비슷하다” 등의 피상적 표현만 있고, 구체적인 데이터, 방법, 맥락 설명이 없음.

2점: 주제적 관련성이 명확하고 논리적으로 타당함. 추천 사유에 구체적인 이유(예: 동일한 연구 분야, 유사한 데이터 유형, 같은 분석 방법 등)가 제시되지만 세부 비교나 새로운 통찰이 부족함.

3점: 매우 드문 경우로, 두 항목이 거의 동일한 연구 목표나 데이터 구조를 공유하면서도 추천 근거가 세부 수준에서 정교하게 연결됨. 방법론, 데이터, 결과 등 여러 측면의 논리적 대응이 완벽함.

■ 점수 분포 지침

- 대부분의 추천이 2점에 물리지 않도록 하며, 판단이 애매한 경우에도 과감히 0점 또는 1점을 부여

4.2.4 평가 결과

지표	점수
nDCG@10	0.9265
MRR@10	0.9700
Recall@5	1.0000
Precision@5	0.8680
F1@5	0.9214

표 4 Qwen 기반 추천 시스템의 LLM-as-a-Judge 정량 평가 결과

■ 주요 지표 요약

- nDCG@5(0.93), MRR@5(0.97): 관련성 높은 항목을 상위 순위에 정확히 배치함
- Recall@5(1.00), Precision@5(0.87): 관련 항목은 모두 탐지했으나 불필요한 추천이 일부 포함됨
- F1@5(0.92): Recall과 Precision의 균형이 양호함
- 3점 비율(0.37): 평가자가 일부 항목에 과도하게 높은 점수를 부여하는 Leniency Bias 존재

■ 해석

- 모델의 상위 추천은 대부분 관련성이 높고, 순서 일관성이 우수하다.
- Recall이 완벽(1.0)하다는 것은 모든 관련 항목을 탐지했음을 의미하지만 Precision이 상대적으로 낮아 일부 비관련 항목이 함께 포함된다.
- 즉, 포괄성은 높으나 정확도는 약간 과잉 추천된 형태이며 평가자의 관대함으로 인한 점수 상향 편향이 영향을 미친 것으로 보인다.

■ 결론

- Qwen 기반 추천 시스템은 높은 순위 일관성(mDCG, MRR)과 완전한 성능(Recall)을 보였지만 정확도(Precision) 개선과 점수 분포 보정을 통해 향후 과잉 추천을 줄이고 평가 일관성을 높이는 방향이 필요하다.

4.3 정성 평가

4.3.1 평가 개요

정성 평가는 LLM Judge의 평가 타당성(meta-evaluation)을 검증하기 위해 수행되었다. 이는 인간이 직접 새로운 점수를 부여하기보다, LLM이 제시한 평가 근거(judge_reason)가 사실적, 논리적, 일관성 있게 판단되었는지를 검토하는 절차이다. 즉, 인간 평가는 LLM의 판단 자체를 평가하는 “메타평가자(meta-judge)” 역할을 수행한다.

4.3.2 평가 절차

인간 평가는 Qwen 기반 추천 시스템의 추천 사유(reason)와 평가 근거(judge_reason)를 함께 검토하고 LLM의 판단이 다음 세 가지 기준에 부합하는지 판단하였다.

확인 항목	판단 기준
사실 정확성	추천 사유나 평가 근거의 사실성
논리 일관성	추천 사유의 주장과 근거가 논리성
평가 일치성	LLM의 점수와 위 논리의 일관성

표 5 정성 평가를 위한 인간 평가자의 판단 기준

4.3.3 평가 데이터셋

정량 평가 데이터셋(qwen_llm_judge_results.json)과 동일하되, 대표 사례를 선정해 진행하였다. 대표 사례는 LLM이 한 데이터셋에 대한 추천 결과를 0~3점 전 구간으로 판단한 사례인 “Moturiki 1953 to NZVD2016 Conversion” 데이터셋의 Qwen 기반 추천 시스템의 추천 사유와 LLM이 판단한 결과 4건으로 선정했다.

4.3.4 점수대별 인간 평가자 평가

▪ 3점 사례

- 추천 데이터: Wellington 1953 to NZVD2016 Conversion

Qwen 기반 추천 시스템(요약): 뉴질랜드의 1953년 기준 좌표계를 2016년 최신 좌표계로 변환하는 동일 주제를 다루며 웰링턴 지역의 구체적 특성과 정밀한 변환 파라미터를 제공함으로써 고정밀 지도 작업에 실질적 도움을 줌.

LLM Judge: 주제적 일치성과 지역 세부 근거 모두 구체적으로 제시되어 논리적, 전문적 완성도가 높음.

- 인간 평가자 판단: 사실 오류가 없고 논리적으로 유사하며 근거도 충분하므로 LLM의 판단

은 타당하다.

- 2점 사례

- 추천 데이터: Gisborne 1926 to NZVD2016 Conversion

Qwen 기반 추천 시스템(요약): 두 데이터 모두 NZVD 변환을 다루며 지역적 변형 요소와 수준 차이를 반영한 구체적 조정 정보를 제공하는 점을 강조함.

LLM Judge: 주제 일치성은 명확하나 방법론적 연결성이나 실제 적용 가능성에 대한 구체성이 부족함.

- 인간 평가자 판단: 사실 오류가 없고 직접적 적용 근거의 논리 연결이 부족하므로 LLM의 판단은 타당하다.

- 1점 사례

- 추천 데이터: Napier 1962 to NZVD2016 Conversion

Qwen 기반 추천 시스템(요약): 동일한 좌표계 변환 주제를 공유하며, Napier 변환 결과가 Moturiki보다 더 정밀함.

LLM Judge: 주제적 관련성은 있으나 지역별 좌표계의 정밀도를 단순 비교하는 것은 논리적 비약임.

- 인간 평가자 판단: 사실 오류가 없으며 정밀도 비교를 통한 접근 자체는 어느 정도 타당한 해석으로 볼 수 있다. 따라서 해당 비교를 논리적 비약이라고 단정하기는 어렵고 LLM의 판단은 다소 타당하지 않다.

- 0점 사례

- 추천 데이터: Auckland 1946 to NZVD2016 Conversion

Qwen 기반 추천 시스템(요약): 뉴질랜드의 오래된 좌표계를 현대 기준 NZVD2016으로 변환하며 뉴질랜드 주요 도시인 애들레이드의 구 좌표계를 기반으로 한 지역적 사례임.

LLM Judge: 애들레이드는 호주 도시로, 추천 사유의 핵심 개념 오류로 인해 논리적 일관성이 무너졌다고 판단.

- 인간 평가자 판단: 명백한 사실 오류가 존재하며 LLM이 정확히 지적한 것은 옳은 판단이나 사실 오류 지적에만 그쳐 추가적인 분석이 부족하다. 따라서 LLM의 판단은 타당하나, 근거의 심층도는 부족하다.

4.3.5 평가 결과

평가 결과

인간 평가자는 Qwen 기반 추천 시스템이 생성한 추천 사유와 LLM Judge가 부여한 점수 및 근거(judge_reason)를 함께 검토하여 각 점수 구간(0 ~ 3점)의 타당성을 평가하였다. 그 결과, LLM Judge의 평가는 전반적으로 높은 일관성과 논리적 타당성을 보였다. 3점과 2점 사례에서는 주제의 일치성과 구체적 근거 제시가 명확했으며, 특히 3점 사례(Wellington)는 사실적 오류가 전혀 없고 세부 근거가 구체적이어서 인간 평가자와 LLM의 판단이 완전히 일치하였다. 2점 사례 (Gisborne) 역시 주제 일치성은 높았으나, 방법론적 연결성과 적용 가능성에 대한 설명이 다소 부족하다는 점에서 LLM의 평가(2점)가 적절하다고 판단되었다.

1점 사례(Napier)의 경우, LLM은 “정밀도 비교는 논리적 비약”으로 판단했으나 인간 평가자는 “정밀도 비교 자체는 일정 부분 의미 있는 해석”이라고 보아 LLM의 판단이 다소 과소평가된 측면이 있다고 평가하였다.

0점 사례(Auckland)에서는 Qwen이 생성한 추천 사유에 명백한 사실 오류가 존재했으며, LLM Judge가 이를 정확히 지적하여 0점으로 평가한 것은 타당하였다. 다만, 사실 오류 지적에 그쳤고 추가적 분석은 부족했다는 점이 지적되었다.

이상의 결과를 요약하면 다음과 같다.

대표 사례	인간 평가 결과 요약	판단 일치도
3점 (Wellington)	사실적, 논리적 타당성 모두 충족	완전 일치
2점 (Gisborne)	주제 일치, 구체성 다소 부족	일치
1점 (Napier)	논리 비약 판단 과도, 부분 불일치	부분 일치
0점 (Auckland)	사실 오류 지적 정확, 심층성 부족	일치

표 6 정성 평가를 위한 인간 평가자의 판단 기준

결론

전반적으로 LLM Judge는 추천 사유의 논리적 일관성과 사실적 정확성을 안정적으로 평가하였으며, 인간 평가자 역시 대부분의 사례에서 LLM의 판단에 동의하였다.

다만 일부 사례(1점)에서는 논리적 비약 여부 판단에서 해석 차이가 나타났고, 0점 사례에서는 사실 오류 탐지는 정확했으나 근거의 심층성이 제한적이었다.

이러한 결과는 LLM Judge가 정성 평가자(Judge)로서 충분히 신뢰할 만한 수준의 판단 능력을 보였음을 의미한다.

5. 결론 및 기대 효과

본 프로젝트를 통해 LLM과 임베딩 모델을 결합한 하이브리드 추천 에이전트를 성공적으로 개발했다. 개발된 에이전트는 DataON에 등록된 데이터의 맥락을 깊이 있게 이해하고, 연구자에게 필요한 관련 논문과 데이터셋을 높은 정확도로 추천한다.

연구 생산성 향상 관련 데이터·논문 탐색 시간을 단축 / 핵심 연구 집중 가능

데이터 활용도 제고 숨겨진 관련 데이터 발굴 / 맥락 설명으로 활용 가치 증가

플랫폼 가치 증대 지능형 추천 기능으로 DataON을 동적 지식 플랫폼으로 발전

융합 연구 촉진 서로 다른 분야 데이터와 논문 연결, 융합 연구 기회 제공

그림 2 추천 에이전트 기대 효과 요약

6. 확장 가능성

본 추천 에이전트는 향후 더욱 발전된 연구 지원 도구로 성장할 수 있는 잠재력을 가지고 있으며, 다음과 같은 확장 방향이 있다.

6.1 대화형 챗봇 인터페이스 도입

단방향 추천에서 벗어나, 사용자가 추천 결과에 대해 추가 질문을 하거나 검색 조건을 조정할 수 있는 대화형 챗봇 인터페이스를 도입할 수 있다.

예를 들어, “추천된 논문 중 '딥러닝'을 사용한 것만 보여줘”와 같은 후속 질문을 통해 보다 동적이고 정교한 탐색 경험을 제공한다. 이를 통해 사용자는 단순 정보 수신자가 아니라, 능동적으로 정보를 탐색하고 정제하는 주체가 될 수 있다.

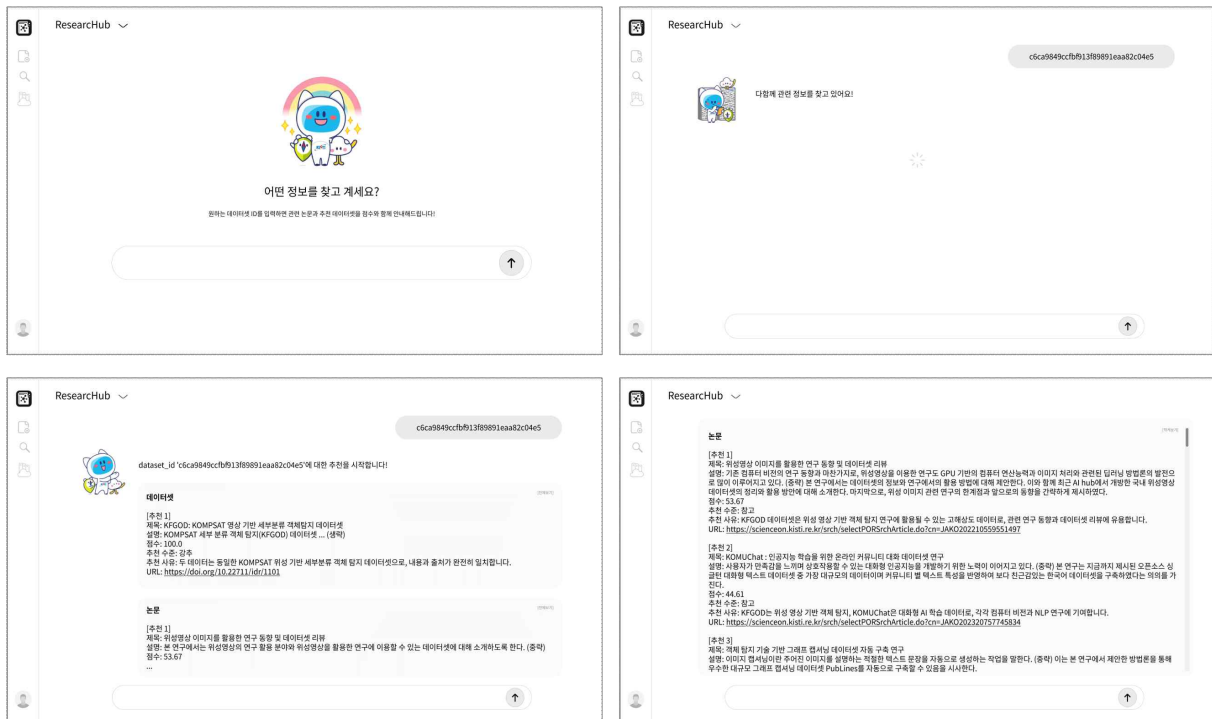


그림 3 챗봇 인터페이스 UI 시안 (사용자 입력 → 추천 결과 순서)

6.2 다국어 지원 및 글로벌 데이터셋 확장

한국어 중심으로 구현된 모델을 다국어 임베딩 및 LLM으로 확장하면, 영어 및 기타 언어로 작성된 논문과 데이터셋까지 추천 범위를 넓힐 수 있다.

이를 통해 국내 연구자들은 글로벌 연구 동향을 손쉽게 파악하고, 해외 연구자와의 협업 기회를 확대할 수 있다.

6.3 사용자 맞춤형 개인화 추천

사용자의 검색 이력과 관심 분야를 학습하여 맞춤형 추천을 제공할 수 있다.

예를 들어, 특정 사용자가 '의료 AI' 분야 데이터를 자주 검색한다면, 해당 분야의 최신 논문이나 신규 데이터셋을 선제적으로 추천하는 프로액티브 연구 비서 역할을 수행할 수 있다.